

Project Presentation

PPO agent for pendulum stabilisation

Presented by :

Ydin Arseniit

Pavloskiy Ivan

Moskalenko Fedor

2026


ITMO University

Постановка задачи

Тройной перевёрнутый маятник представляет собой нелинейную динамическую систему с высокой размерностью пространства состояний. Управление осуществляется единственной силой, прикладываемой к тележке.

Для успешного решения задачи агент должен:

- 01 Накопить необходимую энергию
- 02 Выполнить точный заброс маятника



- 03 Минимизировать ошибку относительно целевого положения
- 04 Удерживать систему в состоянии устойчивого равновесия
- 05 Соблюдать ограничения на движение тележки и скорости звеньев

Среда моделирования

Обучение полностью проводится в физическом симуляторе MuJoCo, обеспечивающем точное моделирование динамики многосвязных механизмов.


Используемый стек:

Язык Программирования: Python

Физический симулятор: MuJoCo

Библиотеки для RL и ML: Gymnasium, Stable-Baselines3, PyTorch, OpenCV, numpy

Обучение проводилось при помощи CUDA



Для ускорения обучения одновременно работают 25 параллельных сред, каждая из которых независимо собирает опыт взаимодействия агента с окружающей средой.


Пространство состояний

Нейронная сеть получает наблюдение размерностью 15 признаков.

В состояние входят:

- положение и скорость тележки;
- синус и косинус каждого из трёх углов;
- угловые скорости всех звеньев;
- ошибка относительно целевого положения;
- последнее управляющее воздействие.

Использование синуса и косинуса позволяет избежать разрыва представления углов при переходе через $\pm\pi$ и делает обучение более устойчивым.



Reward Function

Вознаграждение = [Награда за точность] + [Бонус за прогресс] + [Специфичный бонус фазы] - [Штрафы за нестабильность] - [Критические штрафы]

- [Награда за точность]: Основной стимул. Вычисляется как экспоненциальная функция от текущей ошибки слежения (разницы между текущими и целевыми углами сочленений). Чем ближе агент к цели, тем выше значение. Параметры функции меняются: в фазе удержания требования к точности жестче.
- [Бонус за прогресс]: Награда за динамику. Начисляется, если текущая ошибка слежения стала меньше, чем на предыдущем шаге симуляции.
- В фазе раскачки (агент далеко от цели): это бонус за набор кинетической энергии, стимулирующий агента поднять маятник.
- В фазе стабилизации (агент у цели): это бонус за удержание, который накапливается за каждый последовательный такт нахождения в целевой стабильной зоне.
- [Штрафы за нестабильность]: Вычеты за нежелательные побочные действия. Включают пенализацию за отклонение тележки от стартовой позиции, высокую линейную скорость тележки и избыточную скорость вращения сочленений.
- [Критические штрафы]: Фиксированный крупный вычет за выход за допустимые физические пределы симуляции (досрочное завершение) или за генерацию некорректных математических значений (NaN).

Curriculum Learning

Постепенное усложнение обучения


Для ускорения обучения используется подход Curriculum Learning.

Во время каждого эпизода случайным образом выбирается один из сценариев:

- старт из нижнего положения;
- старт рядом с целевой конфигурацией;
- старт с умеренным отклонением;
- старт с сильным отклонением.

В зависимости от этапа обучения, вероятности появления в конкретном положении изменялись вместе с возможными отклонениями и

Такой подход позволяет сначала научить агента стабилизации, затем захвату цели и только после этого — полноценному swing-up практически из любого начального состояния.



Процесс обучения PPO

Обучение всегда продолжается от ранее сохранённой модели, на данный момент содержащей уже более 430 миллионов шагов взаимодействия (и более 1млрд удаленных шагов).

Используются:

- алгоритм PPO;
- нормализация наблюдений VecNormalize;
- регулярное сохранение контрольных точек;
- автоматическая оценка качества на лёгких и сложных тестах;
- постепенное уменьшение скорости обучения для более точной настройки политики.

Для ускорения обучения одновременно используются 25 параллельных сред, что позволяет значительно увеличить скорость сбора опыта и повысить эффективность обучения. После каждой итерации данные из всех сред объединяются, и на их основе обновляются параметры нейронной сети.

Во время обучения отдельно оценивается качество работы агента на простых и сложных сценариях, что позволяет контролировать не только скорость обучения, но и способность политики к обобщению. Все вычисления выполняются на графическом процессоре с использованием CUDA, а параметры модели и статистика нормализации регулярно сохраняются для возможности продолжения обучения без потери накопленного опыта.

Полученные результаты

На данный момент агент полностью освоил управление для первого целевого положения маятника. В процессе обучения была сформирована устойчивая стратегия, позволяющая последовательно выполнять все необходимые этапы управления без заранее заданных траекторий или классических регуляторов.

Агент способен:

- самостоятельно раскачивать маятник из нижнего положения;
- накапливать необходимую кинетическую энергию;
- выбирать момент для выполнения заброса;
- точно переводить систему в первое целевое состояние;
- стабилизировать маятник после достижения цели и длительное время удерживать равновесие.

По результатам тестирования вероятность успешного выполнения полного сценария превышает 85%. В большинстве запусков агент достигает целевого состояния без столкновения тележки с ограничителями, а после заброса сохраняет устойчивость без повторного раскачивания, что подтверждает эффективность разработанной функции вознаграждения и выбранной методики обучения.

Следующие этапы проекта

Следующим этапом станет обучение единой политики для всех семи целевых конфигураций маятника.

После этого планируется:

Short-term:

- Повысить устойчивость стабилизации;
- Обучить переключению между различными целевыми положениями;

Mid-term:

- Подключить систему компьютерного зрения;
- Заменить идеальные данные симулятора обработкой изображения с камеры;

Long-term:

- Перенести разработанный алгоритм на физический стенд.

Big Thanks!